Porównanie modeli klasyfikacji binarnej na podstawie danych dotyczących diagnozy chorób serca.

Spis treści

1. Cel. 2
2. Dane. 2
   2.1. Opis zbioru danych. 2
   2.2. Rozkłady danych w zależności od występowania choroby. 3
3. Przygotowanie danych. 6
4. Modelowanie i ewaluacja. 7
   4.1. Wybór modeli. 7
   4.2. Model Random Forest. 7
   4.3. Model KNN. 9
5. Porównanie modeli. 11
   5.1. Statystyki ewaluacyjne. 11
   5.2. Porównanie dla obserwacji testowych. 13
6. Podsumowanie. 13

1. Cel.

Celem przeprowadzonego modelowania jest budowa i porównanie modeli klasyfikacyjnych na podstawie danych dotyczących chorób serca.

2. Dane.

2.1. Opis zbioru danych.

Dane dotyczą zachorowań na choroby serca, które są jedną z głównych przyczyn zgonów w dzisiejszym świecie. Zbiór zawiera 12 zmiennych, w tym Heart Disease, która będzie wartością modelowaną. Wskazuje ona na to, czy u danego pacjenta występuje choroba serca (wartość 1), czy nie (wartość 0). Inne zmienne to zarówno parametry demograficzne, jak i wyniki badań klinicznych:

- Age: wiek pacjenta,
- Sex: płeć biologiczna,
- ChestPainType: typ bólu w klatce piersiowej, z klasyfikacją na 4 rodzaje (brak bólu- ASY, typowa dusznica- TA, nietypowy ból wieńcowy- ATA i ból niezwiązany z sercem- NAP),
- RestingBP: ciśnienie krwi w spoczynku,
- Cholesterol: poziom cholesterolu w surowicy krwi,
- FastingBS: poziom cukru na czczo, z przypisaniem wartości 0 dla cukru normalnego poniżej 120 mg/dl oraz 1 dla cukru wyższego
- RestingECG: wynik EKG w spoczynku (z trzema kategoriami dla normalnego EKG- Normal, nieprawidłowości przy przedwczesnym skurczu serca- ST oraz przerostu lewej komory serca-LVH),
- MaxHR: maksymalne tętno osiągnięte przy wysiłku,
- ExcerciseAngina: wskazuje na to, czy podczas wysiłku wystąpił ból,
- Oldpeak: wartość spadku odcinka ST w EKG, odpowiadającego za wskazanie na przedwczesny skurcz serca,
- ST_Slope: nachylenie odcinka ST przy wysiłku (wzrastający- Up, opadający- Down i stały- Flat).

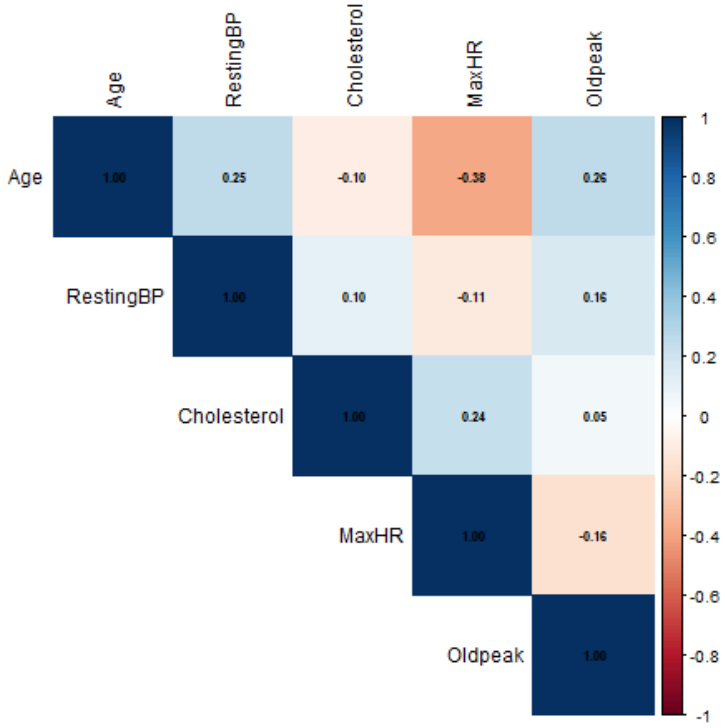

Rysunek 1- Zależności między zmiennymi opisującymi.

Korzystając z biblioteki corrplot wyświetlono macierz współczynników korelacji Pearsona dla zmiennych numerycznych należących do zbioru danych. Na wykresie nie widać zależności ze zmienną modelowaną, jednak wskazane relacje, osiągające w większości przypadków niskie wyniki (wszystkie poniżej 0.5 i powyżej -0.5), wskazują na brak powiązań liniowych między zmiennymi opisującymi zmienną Heart Disease.

2.2. Rozkłady danych w zależności od występowania choroby.

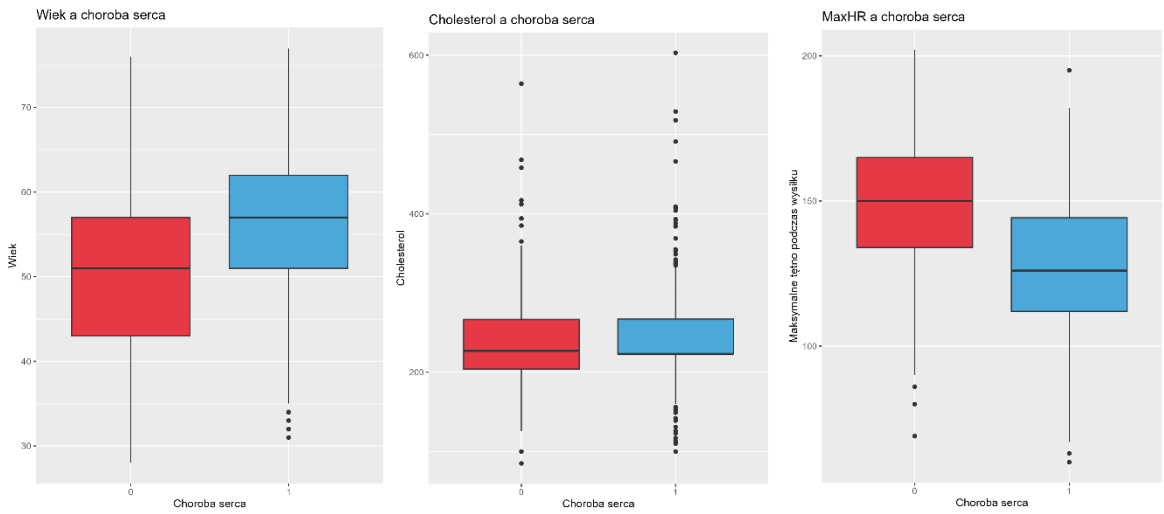

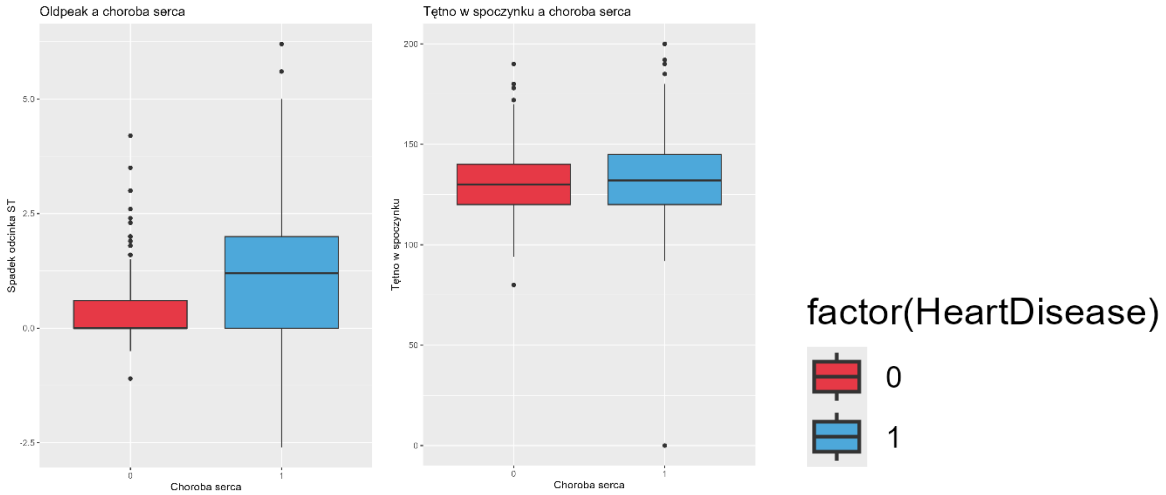

Rysunek 2- Rozkłady zmiennych numerycznych.

Dla większości danych numerycznych na pierwszy rzut oka widać różnicę między wartościami parametrów dla zdrowych i chorych pacjentów. Ta druga grupa charakteryzuje się wyższą medianą wieku, a także rozkładem między kwartylowym.

Dla cholesterolu, dane przyjmują bardzo podobne poziomy. Mimo oczekiwanych większych wyników dla pacjentów chorych nie występują takie, co może wynikać z wielu braków danych w tej kolumnie. Brakujące dane zostały imputowane metodą mediany, aby nie tracić danych do dalszej analizy.

Osoby zdrowe osiągają wyższe tętno przy wysiłku fizycznym. Mediana dla tej grupy osiąga 150 bpm (uderzeń serca na minutę), a dla grupy osób chorych jedynie około 125 bpm.

Chorujący pacjenci mają często wyższe nachylenie spadku odcinka ST na wykresie EKG. Idealnie powinno wynosić ono 0, a mediana tego wskaźnika dla osób, u których wyryto chorobę serca to 1.25.

Jedynie wykres tętna w spoczynku pokazuje podobne wyniki dla obu testowanych grup. Widać jednak, że w porównaniu do tętna w czasie wysiłku, wartości nie wzrastają dla chorych pacjentów, tak jak dla zdrowych.

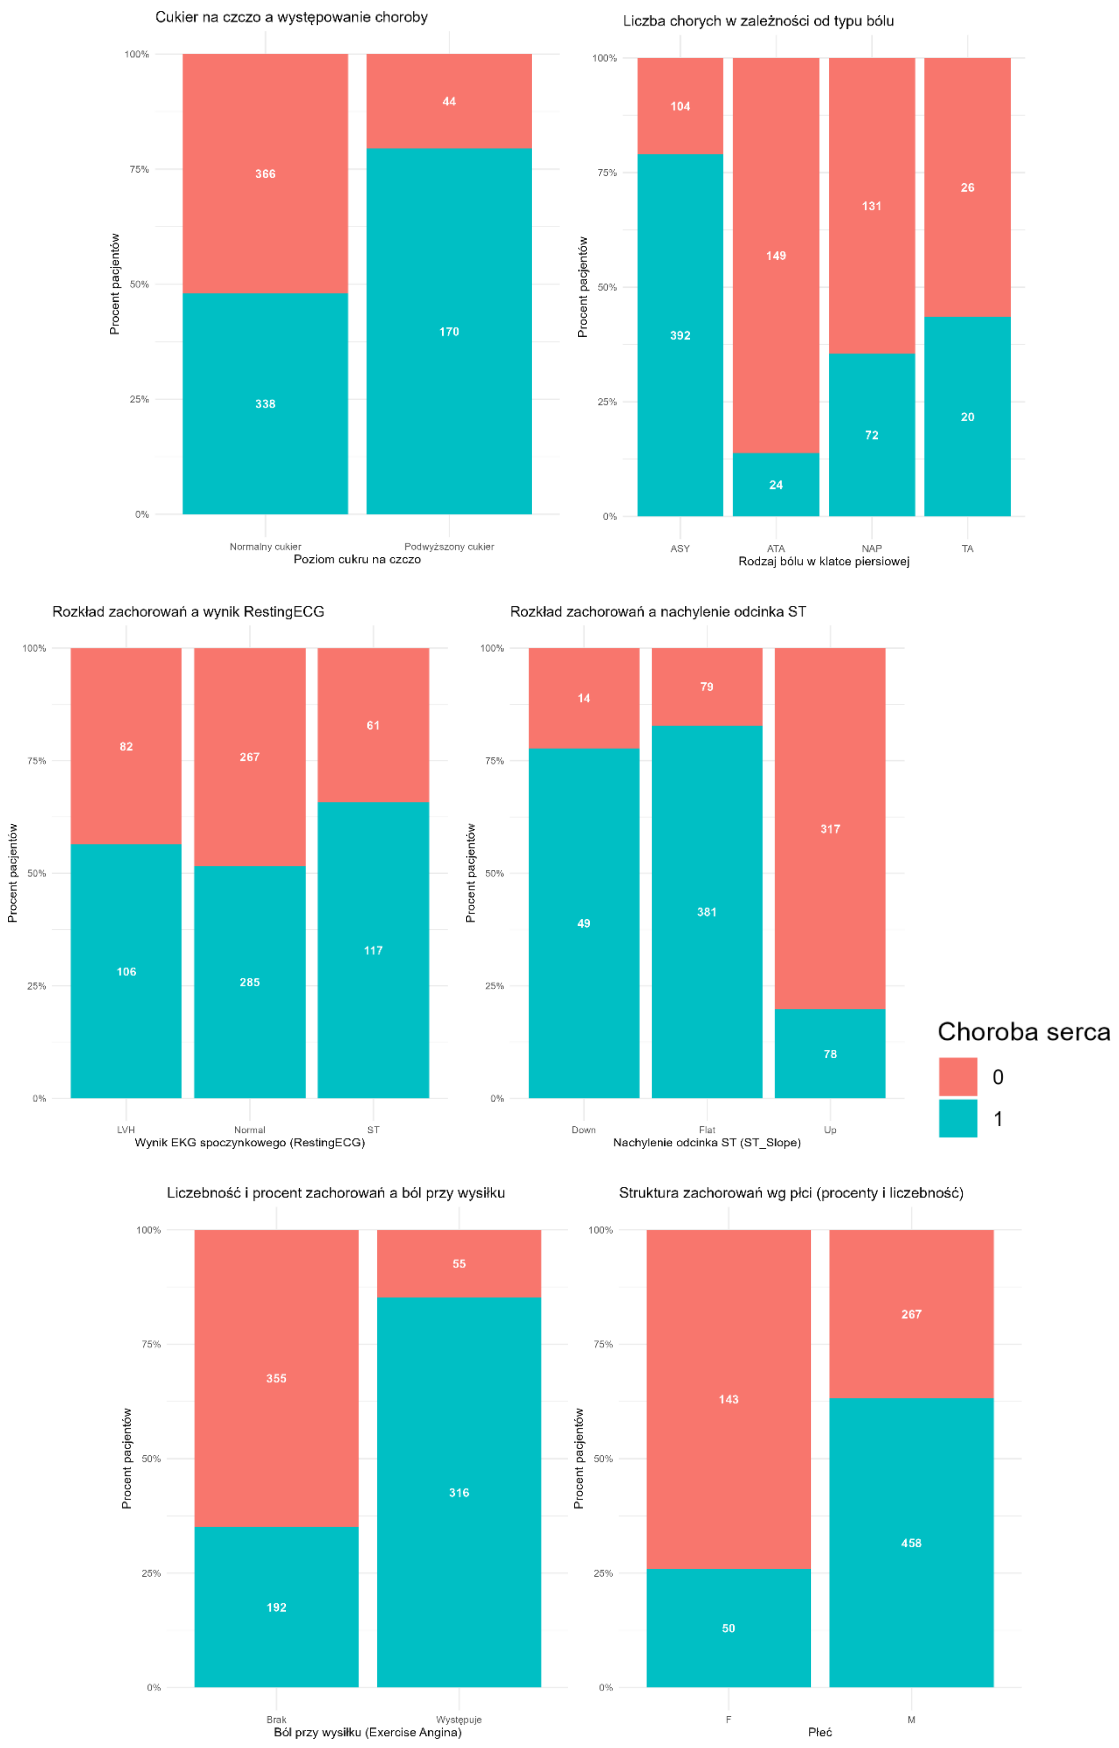

Rysunek 3- Rozkłady zmiennych kategorycznych.

Wykres pierwszy wyraźnie pokazuje, że wśród osób, które mają podwyższony poziom cukru, znajdują się w znacznej większości te, u których zdiagnozowano chorobę serca. Jest to ponad 75% takich pacjentów, gdzie wśród grupy z prawidłowymi wynikami jest to niecała połowa.

Paradoksalnie, wśród pacjentów, którzy nie skarżyli się na ból klatki piersiowej (ASY) około 80% to osoby chore. Może to wynikać z trudności wykrywania nieprawidłowości i niezapobieganiu rozwoju choroby. Podobnie w grupie osób z występującymi bólami znaczna większość okazała się zdrowa, niezależnie od rodzaju bólu.

Dla kategorii związanych ze statycznym EKG ilość przypadków wykrytej choroby jest podobna i wskazuje na około 50-60%.

Nachylenie odcinka ST w EKG wskazuje, że najwięcej zdrowych pacjentów jest w grupie z wzrastającym tym odcinkiem. Jest to stan oczekiwany i normalny dla pracy serca. Dla grup, u których wykryto obniżenie lub wywłaszczenie wykazano duży procent pacjentów chorych (około 80% dla obu grup).

Na kolejnym wykresie widać znaczną przewagę ludzi chorych, w grupie skarżącej się na ból serca w trakcie wysiłku (około 85%). Osoby chorujące to około 30% pacjentów bezobjawowych, którzy stanowią około 60% wszystkich badanych.

Na ostatnim wykresie widać, że aż 75% badanych to mężczyźni, wśród których około 60% choruje na serce, a u kobiet jest to jedynie 25%.

3. Przygotowanie danych.

Ze względu na występowanie danych kategorycznych wykonano binarne kodowanie zmiennych. Kolejnym kategoriom dla każdej takiej zmiennej przypisano wartości 0 i 1, a następnie utworzono nowe kolumny.

Zmienna ST_Slope ma podobny rozkład dla wartości „Down” i „Flat”, dlatego te zmienne zakodowano jako jedną kategorię.

Braki danych w kolumnie zawierającej informacje o poziomach cholesterol u pacjentów imputowano metodą mediany. Pozwoliło to na zachowanie ilości obserwacji do analizy.

W następnym kroku zbiór danych podzielono na 3 mniejsze:

a) Do testowania predykcji (4 obserwacje)
b) Zbiór treningowy (80% pozostałych danych)
c) Zbiór testowy

4. Modelowanie i ewaluacja.

4.1. Wybór modeli.

Model Random Forest został wykorzystany do klasyfikacji i przewidywania, czy u danego pacjenta występuje choroba serca, ze względu na jego użyteczność przy wcześniej wskazanych zależnościach nieliniowych między zmiennymi. Buduje on wiele drzew decyzyjnych i agreguje ich wyniki, co prowadzi do zbudowania dobrego modelu, który jest trudy do przeuczenia i redukuje ryzyko dominacji nietypowych cech pacjenta, jak w przypadku pojedynczych drzew decyzyjnych. Dodatkowo pozwala na wskazanie rankingu ważności zmiennych do przewidywania oraz nie wymaga normalizacji danych, co ułatwia przygotowanie danych.

Model KNN (k- Nearest Neighbours) klasyfikuje obserwację na podstawie podobieństwa do k najbardziej zbliżonych przypadków. Jest również algorytmem klasyfikacyjnym, jednak opiera się on na odległości euklidesowej. Model wymusza skalowanie danych, aby nie dopuścić do dominacji cech przyjmujących wyższe wartości, jak np. cholesterol.

Zestawienie tych modeli pozwala na porównanie algorytmu opartego na wykrywaniu interakcji między zmiennymi i opartego na podobieństwach. W kolejnych etapach pozwala na wybór modelu o większej precyzji diagnostycznej.

4.2. Model Random Forest.

Do zbudowania modelu wykorzystano zbiór treningowy i ustalono ilość drzew na 500. Każde drzewo uczy się na nieco innym podzbiorze danych, a potem wyniki są uśredniane, dzięki czemu nie występuje przeuczenie i model generalizuje wiedzę o pacjentach.

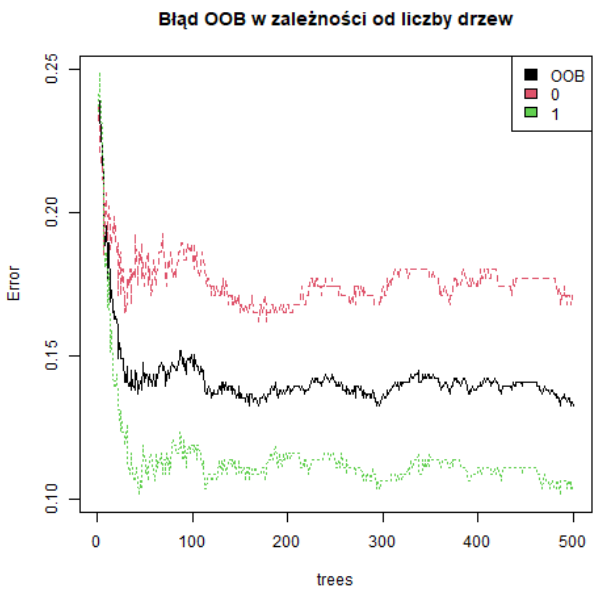

Rysunek 4- Błąd OBB.

Metryka OOB (Out Of Bag) sprawdza skuteczność modelu dla danych nie wylosowanych w Bootstrap dla danego drzewa. Wraz ze wzrastającą ilością drzew maleje ilość błędów, aż dla wybranej wartości 500 wynosi 13.95%.

Kolejną metryką używaną do ewaluacji modelu jest Accuracy (precyzja), które mówi o tym, jak dużo obserwacji ze zbioru testowego udało się poprawnie przewidzieć na podstawie modelu. Oprócz tego korzysta się z macierzy pomyłek, która dokładnie wskazuje jakie wartości (do jakiej klasy) przypisano obserwacjom, a jakie są w rzeczywistości.

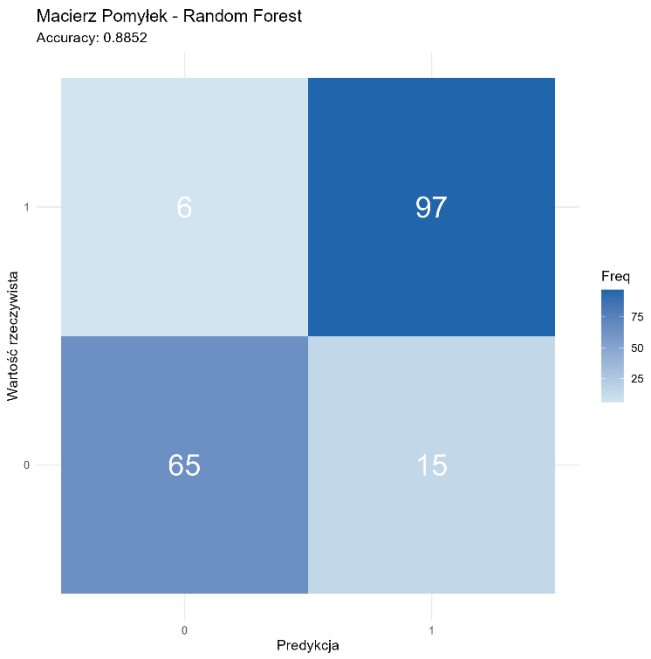

Rysunek 5- Macierz pomyłek Random Forest.

Wynik parametru Accuracy wskazuje, że ponad 88% obserwacji udało się poprawnie zakwalifikować. Model u 15 osób zdiagnozowałby chorobę, mimo jej niewystępowania i nie wykryłby jej u 6 osób (False Negative).

Random Forest daje możliwość analizy, które zmienne są najbardziej kluczowe przy klasyfikacji:

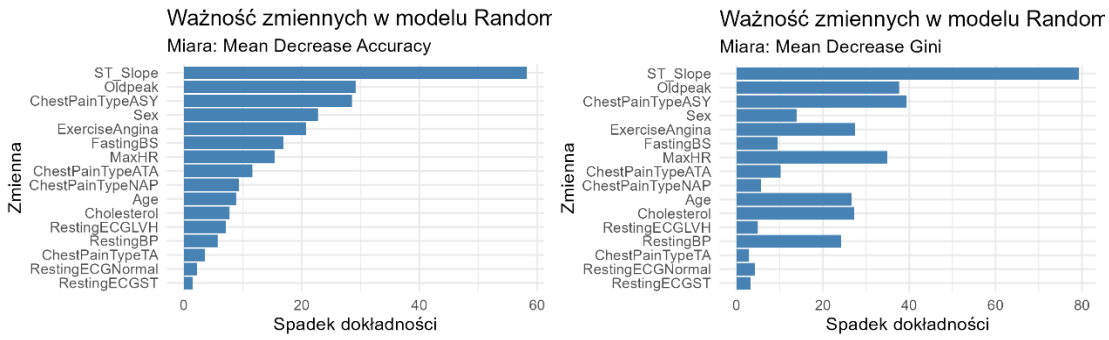

Rysunek 6- Ważność zmiennych w modelu RF.

Mean Decrease Accuracy mówi o tym jak spadnie dokładność modelu, jeżeli wartości danej zmiennej zostaną zmieszane między pacjentami. Na wykresie widać, że zmienną najbardziej kluczową dla diagnozy jest ST_Slope, a najmniejsze znaczenie mają wyniki statycznego EKG.

Mean Decreased Gini wskazuje na to, jak rozdzielone od siebie są dane grupy pacjentów, czyli jak dane zmienne separują chorych od zdrowych pacjentów. Ponownie najbardziej znaczącą zmienną jest tutaj ST_Slope.

4.3. Model KNN.

W celu zbudowania modeli KNN należało utworzyć nowe zbiory danych testowych i treningowych, ponieważ ten algorytm wymaga zmiennych zeskalowanych. Do normalizacji użyto algorytmu Z-score, dzięki któremu każda zmienna przyjmuje średnią 0 i odchylenie standardowe równe 1.

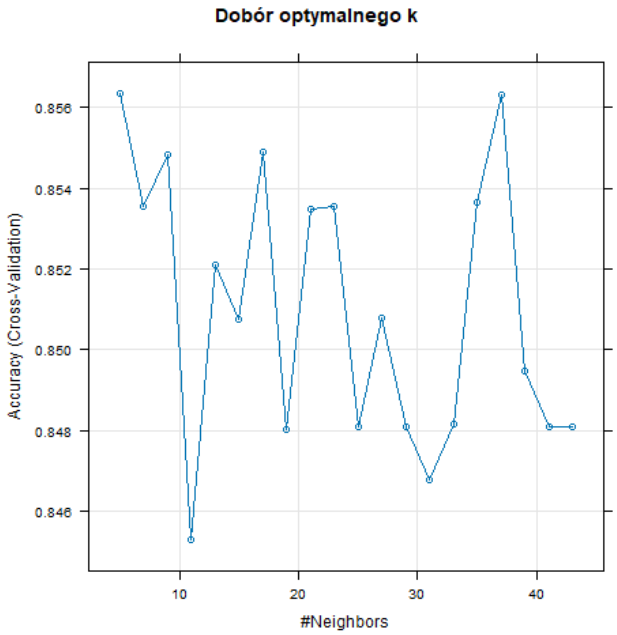

Rysunek 7- Wybór parametru k.

Następnie korzystając z kroswalidacji sprawdzono optymalne wartości parametry k dla modelu. Na podstawie metryk Accuracy i Kappa (odjęta możliwość przypadkowego trafienia) wybrano k (ilość sąsiadów) równe 5.

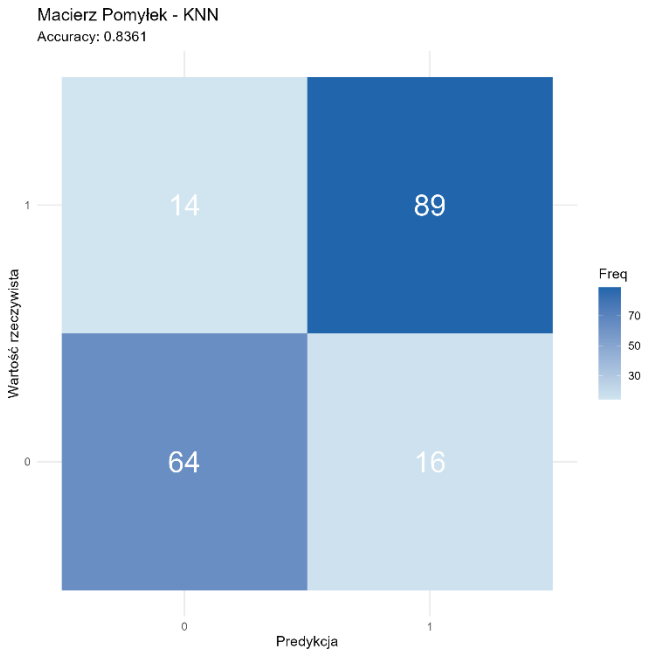

Rysunek 8- Macierz pomyłek KNN.

Macierz pomyłek dla KNN mówi, że poprawnie udało się zaklasyfikować ponad 83% przypadków.

5. Porównanie modeli.

5.1. Statystyki ewaluacyjne.

Do porównania modeli wybrano kilka metod. Pierwsza z nich dotyczy porównania macierzy pomyłek modeli. Jak wskazano na rysunkach 5 i 8, model Random Forest częściej poprawnie diagnozuje i klasyfikuje pacjentów, szczególnie wskazuje na choroby u pacjentów, u których rzeczywiście nastąpiła diagoza. Model KNN znacznie częściej wskazuje na brak choroby w przypadkach gdzie ona jednak występuje. Wyniki negatywne dla obu modeli występują podobnie często.

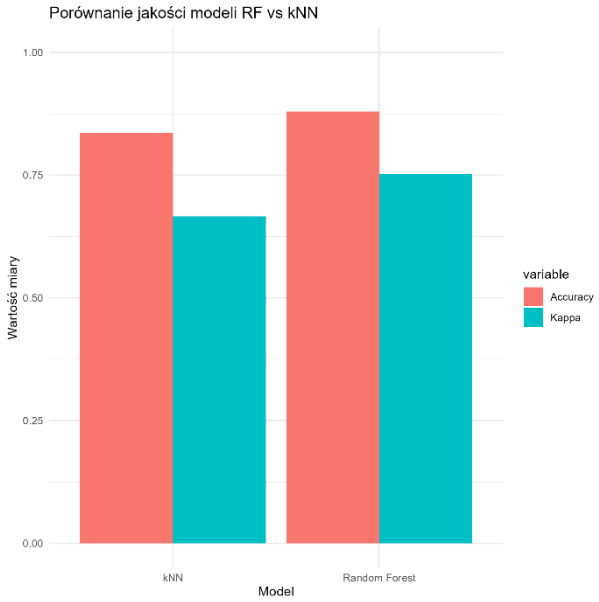

Rysunek 9- Porównanie jakości modeli.

Wyższa wartość współczynników Accuracy i Kappa dla modelu Random Forest ponownie pokazują jego wyższą wartość diagnostyczną w porównaniu do modelu KNN.

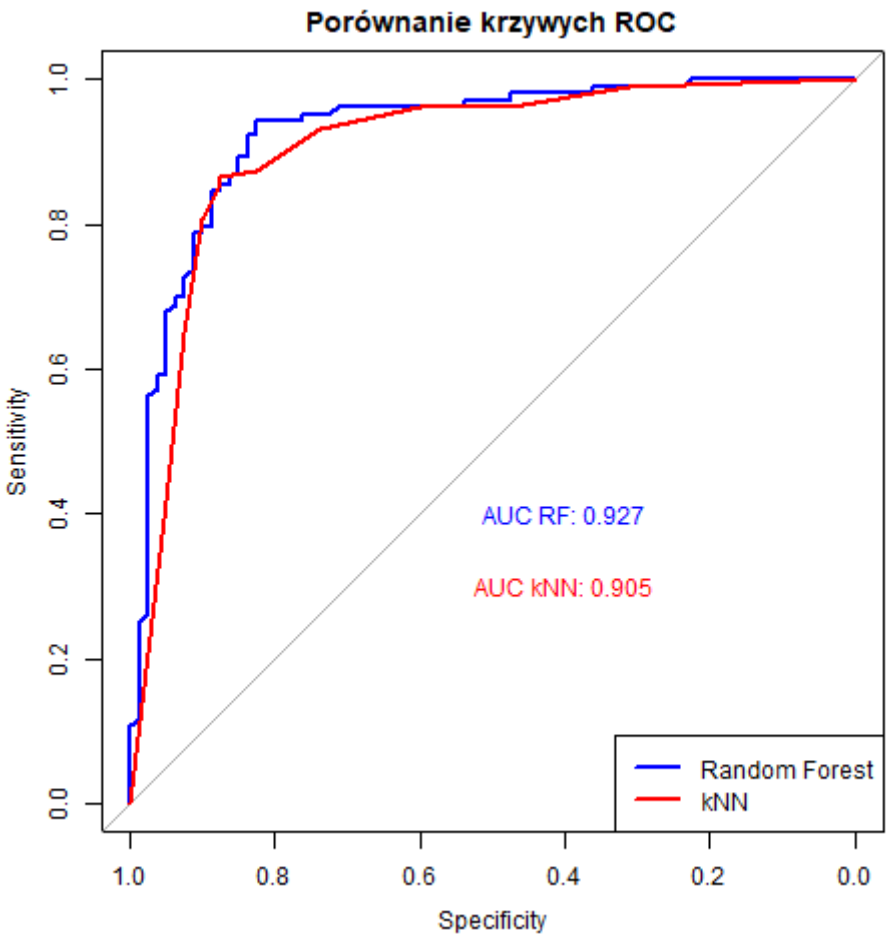

Rysunek 10- Krzywe ROC.

Innym ważnym parametrem wykorzystywanym do oceny modeli klasyfikacyjnych binarnych jest krzywa ROC (Receiver Operating Characteristics). Pokazuje on stosunek pacjentów chorych poprawnie zdiagnozowanych (Sensitivity) do tych błędnie uznanych za chorych (1-Specifity). Krzywa dla modelu Random Forest znajduje się powyżej krzywej KNN, co oznacza, że jest on lepszym diagnostą.

Krzywe ROC wyznaczają pod sobą pola, które nazywane są AUC (Area Under the Curve). Wskazują na prawdopodobieństwo wskazania przez algorytm wyższego prawdopodobieństwa choroby osobie chorej niż zdrowej. Tę metrykę wyznacza się przez obliczenie pola pod krzywą ROC.

Ponownie, dla modelu KNN wartość jest mniejsza (0.91) niż dla Random Forest (0.93), co wskazuje na jego gorsze działanie. Mimo to, wartości dla obu modeli są stosunkowo wysokie (>0.9), co oznacza, że oba modele doskonale radzą sobie z separacją klas i rozumieją strukturę danych.

5.2. Porównanie dla obserwacji testowych.

ID	Prawda	RF_Pred	kNN_Pred
1	0	0	0
2	1	1	1
3	0	0	0
4	0	0	0

Rysunek 11- Porównanie wyników.

Przed rozpoczęciem modelowania pobrano ze zbioru danych próbkę 4 przypadkowych obserwacji. Na koniec, stworzonymi modelami, wykonano predykcję diagnozy pacjentów. Dla obu modeli te konkretne przypadki zdiagnozowano poprawnie: pacjent pierwszy, trzeci i czwarty byli zdrowi, a drugi, z chorobą serca otrzymał taką diagnozę.

6. Podsumowanie.

Na postawie przeprowadzonej analizy wskazano najważniejsze parametry wpływające na rozwój chorób serca. Okazały się nimi ST_Slope (nachylenie typu płaskiego i opadającego), brak bólu w klatce piersiowej i występowanie bólu podczas wysiłku.

Random Forest okazał się w porównaniu do modelu KNN lepszym predykatorem osiągając wartości Accuracy i Kappa na poziomach 89% i 75%. Ten predykator okazał się również bardziej stabilny osiągając ponownie wyższe AUC (93%) i ROC.

Przykład weryfikacji na próbie testowej wykazał wysoką użyteczność modeli, poprawnie diagnozując wszystkie 4 obserwacje kliniczne.

Powyższe wyniki potwierdzają, że algorytmy mogą skutecznie wspierać diagnozy pacjentów z grup wysokiego ryzyka. Należy jednak pamiętać o nie zastępowalności czynnika ludzkiego – modele nie są stuprocentowo skuteczne, należy ich diagnozę weryfikować.